

Algorithmen und Datenstrukturen

Theoretische Grundlagen der Informatik

Prof. Dr. rer. nat. Jörg Striegnitz

Fachhochschule Aachen
striegnitz@fh-aachen.de

19. April 2024

Algorithmen und Datenstrukturen

Sprachen zur Codierung von Daten

Prof. Dr. rer. nat. Jörg Striegnitz

Fachhochschule Aachen
striegnitz@fh-aachen.de

19. April 2024

1. Sprachen als geeignetes Mittel zur Darstellung aller Ein- und Ausgaben?
2. Ist Σ_{Bool}^* als einzige verfügbare Sprache in einem Computer ausreichend?
3. Wie kann man die Beschreibung einer Sprache systematisieren? »Die Menge aller syntaktisch korrekten JAVA-Programme« gibt wenig Aufschluss darüber, wie ein solches überhaupt aussieht.
4. Wie kann man effektiv und effizient testen, ob $w \in L$ gilt und geht das eigentlich für jedes L ? Wie überprüft man beispielsweise, ob ein JAVA-Programm syntaktisch korrekt ist?

Das EVA-Prinzip

Computer arbeiten nach dem EVA-Prinzip:



Zentrale Frage

Wie kann man **alle möglichen** Ein- / Ausgaben formal codieren?

Beispiel 1.11 (Kodierung von natürlichen Zahlen)

Ein Wort

$$x = x_1 x_2 \cdots x_n \in \Sigma_{Bool}^*$$

mit $x_i \in \Sigma_{Bool}$ für $1 \leq i \leq n$, kann als binäre Darstellung einer Zahl $n \in \mathbb{N}$ betrachtet werden, mit

$$\text{Zahlwert}(x) = \sum_{i=0}^n 2^{n-i} \cdot x_i$$

wobei wir $x_i \in \Sigma_{Bool}$ in naheliegender Weise als natürliche Zahl interpretieren.

Die Umkehrfunktion zu *Zahlwert* bezeichnen wir mit $\text{Bin} : \mathbb{N} \rightarrow \Sigma_{Bool}^*$, wobei *Bin* immer die kürzeste Binärdarstellung liefere (d.h. ohne führende Nullen).

- Kodierungen von $\mathbb{Z} / \mathbb{R} \Rightarrow$ Vorlesung »IT-Grundlagen«

Beispiel 1.12 (Kodierung von Zahlenfolgen (eindimensionales Feld))

Eine endliche Folge von natürlichen Zahlen

$$(n_1, n_2, \dots, n_k) \quad \text{mit} \quad n_i \in \mathbb{N} \quad \text{für } 1 \leq i \leq k$$

kann man wie folgt als Wort über $\Sigma_{Bool} \cup \{\#\}$ darstellen:

$$Bin(n_1)\#Bin(n_2)\#\cdots\#Bin(n_k)$$

Wir nutzen das Symbol $\#$ also als Trennzeichen.

Beachte: später müssen wir uns natürlich auf 0 und 1 beschränken!

Kodierung von Matrizen 1

Beispiel 1.13 (Kodierung von Matrizen (zweidimensionales Feld))

Sei $A \in \mathbb{N}^{m \times n}$ eine $m \times n$ Matrix (mit m Zeilen und n Spalten); z.B.:

$$A = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{pmatrix}$$

mit $a_{ij} \in \mathbb{N}$ für $1 \leq i \leq m$ und $1 \leq j \leq n$.

Dann kodieren wir die Matrix A zeilenweise als Wort über $\Sigma_{Bool} \cup \{\#\}$ wie folgt:

$$\underbrace{b_{11}\#b_{12}\#\cdots\#b_{1n}}_{\text{Zeile 1}} \# \underbrace{b_{21}\#b_{22}\#\cdots\#b_{2n}}_{\text{Zeile 2}} \# \cdots \# \underbrace{b_{m1}\#b_{m2}\#\cdots\#b_{mn}}_{\text{Zeile } m}$$

mit $b_{ij} = Bin(a_{ij})$.

Lesbarkeit?

Kodierung von Matrizen 2

Beispiel 1.14 (Kodierung von Matrizen (zweidimensionales Feld))

Sei $A \in \mathbb{N}^{m \times n}$ eine $m \times n$ Matrix (mit m Zeilen und n Spalten); z.B.:

$$A = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{pmatrix}$$

mit $a_{ij} \in \mathbb{N}$ für $1 \leq i \leq m$ und $1 \leq j \leq n$.

Alternativ könnten wir die Matrix A auch als Wort über $\Sigma_{Bool} \cup \{; .(,)\}$ kodieren:

$$\underbrace{(b_{11}; b_{12}; \cdots; b_{1n})}_{\text{Zeile 1}} \underbrace{(b_{21}; b_{22}; \cdots; b_{2n})}_{\text{Zeile 2}} \cdots \underbrace{(b_{m1}; b_{m2}; \cdots; b_{mn})}_{\text{Zeile } m}$$

(auch hier ist $b_{ij} = \text{Bin}(a_{ij})$).

Effizienz? Einlesen einer Matrix in aus einer Datei?

Kodierung von Matrizen 3

Beispiel 1.15 (Kodierung von Matrizen (zweidimensionales Feld))

Sei $A \in \mathbb{N}^{m \times n}$ eine $m \times n$ Matrix (mit m Zeilen und n Spalten); z.B.:

$$A = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{pmatrix}$$

mit $a_{ij} \in \mathbb{N}$ für $1 \leq i \leq m$ und $1 \leq j \leq n$.

Manchmal hilfreich: Dimensionen der Matrix explizit in die Kodierung aufnehmen; z.B. indem man die Matrix A wie folgt als Wort über $\Sigma_{Bool} \cup \{\cdot, ., (\cdot), (\cdot)\}$ kodiert:

$$\underbrace{(m', n')}_{\text{Dimension}} \underbrace{(b_{11}; b_{12}; \dots; b_{1n})}_{\text{Zeile 1}} \underbrace{(b_{21}; b_{22}; \dots; b_{2n})}_{\text{Zeile 2}} \dots \underbrace{(b_{m1}; b_{m2}; \dots; b_{mn})}_{\text{Zeile m}}$$

wobei $b_{ij} = Bin(a_{ij})$, $m' = Bin(m)$ und $n' = Bin(n)$.

Effizienz? Speicherplatzverbrauch?

Kodierung von Graphen

Graphen sind eine wichtige Datenstruktur in der Informatik

Definition 1.21 (Graph)

Ein **Graph** $G = \langle V, E \rangle$ besteht aus einer endlichen Knotenmenge V und einer Relation $E \subseteq V \times V$ - der Kantenmenge. Abhängig von den Eigenschaften von E unterscheidet man

- **ungerichtete Graphen:** E ist symmetrisch; d.h.:

$$(v_1, v_2) \in E \Leftrightarrow (v_2, v_1) \in E$$


- **gerichtete Graphen:** E ist nicht symmetrisch
- **vollständige Graphen:** $E = V \times V$ (jeder Knoten ist mit jedem anderen verbunden)
- **schleifenfreier Graph:** $\forall (v, v) \in V \times V : (v, v) \notin E$
- Die Bezeichnung von Knoten und Kanten leiten sich aus dem Englischen ab:
 - V : **vertices** - die Knotenmenge
 - E : **edges** - die Kantenmenge
- Wenn wir zwischen gerichtetem und ungerichtetem Graph nicht unterscheiden wollen, sprechen wir allgemein von einem Graph

Darstellung von Graphen

Graphen lassen sich sehr anschaulich darstellen:


Gerichteter Graph

- v ist **Vorgänger** von w
- w ist **Nachfolger** von v
- v und w sind **Nachbarn** bzw. **adjazent**



Ungerichteter Graph

- v und w sind **Nachbarn** bzw. **adjazent**



Anwendungsgebiete für Graphen

Graphen finden vielfache Anwendung; z.B.

- Beziehung zwischen Personen (Knoten entsprechen Personen)
 - Person A kennt Person B
 - Person A ist Vater von Person B
- Verbindungen zwischen Punkten
 - Straßennetz
 - Eisenbahnnetz
 - Telefonnetz
 - Internet
 - elektronische Schaltkreise


Typische Fragestellungen

- Existiert eine Verbindung von A nach B?
- Existiert eine zweite Verbindung, falls diese blockiert ist?
- Was ist die kürzeste Verbindung von A nach B?
- Optimale Rundreise (*Traveling Salesman Problem*)
- Minimaler Spannbaum

Anwendungsbeispiel 1: Das Königsberger Brückenproblem


Das Königsberger Brückenproblem

- 1760 von Leonard Euler formuliert
- **Frage:** Gibt es einen Weg, bei dem man jede Brücke genau einmal überquert und schließlich wieder zum Ausgangspunkt zurückkehrt?
- **Antwort:** Nein!



Graphentheoretische Betrachtung

- Landmassen \mapsto Knoten
- Brücken \mapsto Kanten
- **Frage:** Gibt es einen geschlossenen Kantenzug (Anfangs-=Endknoten), der jede Kante genau einmal durchläuft? (Eulerscher Kreis)



Anwendungsbeispiel 1: Graphentheoretische Betrachtung

Definition 1.22 (Pfad / Kreis / Eulerscher- und Hamiltonscher Kreis)

Sei $G = \langle V, E \rangle$ ein Graph. Eine Folge von Knoten $p = (w_1, w_2, \dots, w_k)$ (mit $w_i \in V$) heißt **Pfad** in G wenn

Ein Pfad heißt $\forall i \in \{1, \dots, k-1\} : (w_i, w_{i+1}) \in E$

- **Kreis**, falls $w_1 = w_k$
(Startknoten = Endknoten)

- **Eulerscher Kreis**, falls er ein Kreis ist und
 $\forall (s, t) \in E : \exists_1 i : s = w_i \wedge t = w_{i+1}$
(jede **Kante** wird genau einmal durchlaufen)

- **Hamiltonscher Kreis**, falls er ein Kreis ist und $\forall v \in V : \exists_1 i : v = w_i$
(jeder **Knoten** wird genau einmal besucht)

Anmerkung: Pfade können wir offensichtlich leicht in Form von Zahlenfolgen kodieren.

Das Königsberger Brückenproblem entspricht der Suche nach einem Eulerschen Kreis in einem ungerichteten Multigraphen.


Definition 1.23 (Gewichtete Graphen)

Ein **gewichteter Graph** $G = \langle V, E, \phi \rangle$ ist ein Graph $\langle V, E \rangle$, erweitert um eine totale Funktion $\phi : E \rightarrow R$, die jeder Kante ein Gewicht zuordnet. R ist dabei eine beliebige Menge (z.B. \mathbb{R}).

- Gewichtete Graphen finden z.B. Anwendung bei der Modellierung von Straßennetzen (Navigationssysteme!):
 - Knoten entsprechen Kreuzungen, Einmündungen, Sackgassen, POIs etc.
 - Kanten sind gerichtet (z.B. Einbahnstraßen)
 - Gewicht entspricht Entfernung

Anwendungsbeispiel 2: Traveling Salesman Problem

Das Traveling Salesman Problem




Gegeben ist eine Menge von **Städten** nebst **Entfernungstabelle**. **Gesucht** ist die günstigste Rundreise, bei der jede Stadt genau einmal besucht wird und die wieder in der Ausgangsstadt endet.



Anwendungsbeispiel 2: Graphentheoretische Betrachtung 1

Beispiel 1.16 (Traveling Salesman Problem)

Wir **modellieren** das Problem durch einen ungerichteten, gewichteten Graphen:



Anwendungsbeispiel 2: Graphentheoretische Betrachtung 2

Definition 1.24 (Pfadgewicht)

Sei $G = \langle V, E, \phi \rangle$ ein gewichteter Graph und $p = (w_1, w_2, \dots, w_k)$ ein Pfad in G . Dann beschreibt

$$\phi(p) = \sum_{i=1}^{k-1} \phi(w_i, w_{i+1})$$

das **Pfadgewicht** von p .

Erste algorithmische Idee:

1. Bestimme $L_{Hamil}(G) = \{w \mid w \text{ kodiert Hamiltonschen Kreis in } G\}$
2. Suche mittels ϕ günstigsten Pfad in dieser Menge

Laufzeiteffizienz, Speicherplatzverbrauch?

Wie berechnet man $L_{Hamil}(G)$ und wie viele Pfade enthält diese Menge?


Die Adjazenzmatrix

Definition 1.25 (Adjazenzmatrix)

Sei $G = \langle V, E \rangle$ ein Graph mit $V = \{v_1, v_2, \dots, v_n\}$. Die **Adjazenzmatrix** $A = (a_{ij})$ zu G ist eine $n \times n$ -Matrix mit

$$a_{ij} = \begin{cases} 1 & \text{falls } (v_i, v_j) \in E \\ 0 & \text{sonst} \end{cases}$$

Beispiel 1.17 (Adjazenzmatrix)




		nach					
		A	1	2	3	4	5
von		A	0	1	0	1	0
			1	0	0	1	0
			0	0	1	0	1
			0	0	0	0	1
			0	0	1	0	0

Beachte: Für ungerichtete Graphen ist die Adjazenzmatrix offenbar symmetrisch!

Beispiel: Kodierung eines Graphen

Beispiel 1.18 (Kodierung eines Graphen)

- Ein Graph ist durch seine Adjazenzmatrix eindeutig repräsentiert:



A		nach				
von		0	1	0	1	0
		1	0	0	1	0
		0	0	1	0	1
		0	0	0	0	1
		0	0	1	0	0

- Wir kodieren die Matrix zeilenweise als Wort über $\Sigma_{Bool} \cup \{\#\}$
- Spaltentrennzeichen hier überflüssig - ein Eintrag ist exakt ein Zeichen lang:


$\underbrace{01010}_{\text{Zeile 1}} \# \underbrace{10010}_{\text{Zeile 2}} \# \underbrace{00101}_{\text{Zeile 3}} \# \underbrace{00001}_{\text{Zeile 4}} \# \underbrace{00100}_{\text{Zeile 5}}$

Kodierung von gewichteten Graphen

Beispiel 1.19 (Kodierung von gewichteten Graphen)

- Zwei Komponenten:
 - Adjazenzmatrix A zur Kodierung von E
 - Gewichtsmatrix W zur Kodierung von ϕ mit $w_{ij} = \phi(v_i, v_j)$

Graph:



Gewichtsmatrix:

		nach				
		0	7	0	6	1
von	0	7	0	1	1	0
	1	0	1	0	6	0
2	6	1	6	0	5	0
3	1	0	0	5	0	0

W könnte wieder zeilenweise kodiert werden


0#111#0#110#1##111#0#1#1#0##0#1#0#110#0##
110#1#110#0#101##1#0#0#101#0

Insgesamt **69** Zeichen.

Kodierung von gewichteten ungerichteten Graphen

Beispiel 1.20 (Kodierung von gewichteten Graphen)

Graph:



Gewichtsmatrix:

		nach				
		0	1	2	3	4
von	0	0	7	0	6	1
	1	7	0	1	1	0
2	0	1	0	6	0	0
3	6	1	6	0	5	0
4	1	0	0	5	0	0

Beobachtung: Die Gewichtsmatrix ist symmetrisch und nur Nullen auf Hauptdiagonale!

Es ist ausreichend das »obere Dreieck« zu kodieren:

111#0#110#1##1#1#0##110#0##101

Insgesamt nur noch 30 Zeichen.



- **Wir haben gelernt**
 - wie man auch komplexe Daten durch Wörter (Sprachen) beschreiben kann

- **Weitere Fragen bezüglich der Kodierung von Daten**

1. Ist Σ_{Bool} , das Alphabet eines Computers, wirklich ausreichend?

[Wir hatten z.B. mit # Hilfssymbole verwendet und Formeln sogar über Σ_{logic} kodiert]

2. Wie viele Wörter enthält eine Sprache, wenn Sie nicht unendlich ist?

[Wie viele Wörter hat z.B. $L_{Hamil}(G) = \{w \mid w \text{ kodiert Hamiltonschen Kreis in } G\}$]

- **Noch zu klären**

- Wie kodieren wir algorithmische Probleme mithilfe von Sprachen?

[Das sind Probleme, die wir durch Algorithmen lösen wollen]

- **Offen gebliebene Fragen zur Kodierung von Daten**

- Gibt es eine zu einem Datum eine kürzeste Darstellung als Wort über einem beliebigem Alphabet?

[Diese Frage hatten wir vertagt]

Bevor wir untersuchen wie man mit Sprachen algorithmische Probleme beschreiben kann, werden wir die offenen Fragen zur Kodierung von Daten beantworten.

Das EVA-Prinzip und unser Modell (bisher)



Kodierung der Ein-/Ausgaben

1. Formale Repräsentation finden (z.B. Folge, Graph) [Modellierung]
2. Kodierung formaler Objekte als Wörter über Σ_i (Eingaben) bzw. Σ_o (Ausgaben) [Implementierung]

Beispiel: Traveling Salesman Problem

Beispiel 1.21 (Ein- und Ausgabe beim Travelling Salesman Problem)

Modell (abstrakte, formale Beschreibung):

- **Eingabe:** Graph $G = \langle V, E, \phi \rangle$ (vollständig, schleifenfrei, ungerichtet)
- **Ausgabe:** Pfad (Kreis) $P = (v_1, \dots, v_k)$

Implementierung (später: Datentypen in konkreter Programmiersprache):

- **Eingabe:** $w \in L_{in}$ mit

$$L_{in} = \{w \in \{0, 1, \#\}^* \mid w \text{ kodiert ungerichteten, gewichteten Graph}\}$$

- **Ausgabe:** $w \in L_{out}$ mit

$$L_{out} = \{w \in \{0, 1, \#\}^* \mid w \text{ kodiert einen Pfad}\}$$

Beachte: Wir betrachten hier nur die Art (den Typ) von Ein- und Ausgabe. Wir legen noch nicht fest, dass die Ausgabe Hamiltonscher Kreis mit minimalem Gewicht sein soll.

Das EVA-Prinzip und unser Modell (bisher)



Beschränkung auf Σ_{Bool}^*

1. Computer arbeiten auf Wörtern aus Σ_{Bool}^*
2. Können wir alle Sprachen auf Σ_{Bool}^* abbilden? [Compiler]


- L_{in} kann unendlich viele Wörter enthalten; Σ_{Bool}^* enthält unendlich viele Wörter.
- **Aufgabe:** jedem Wort $w \in L_{in}$ ein Wort $v \in \Sigma_{Bool}^*$ zuordnen.
 - **Lösung:** Relation $encode \subseteq L_{in} \times \Sigma_{Bool}^*$

Anforderungen an $encode$:

- **Kodierung muss eindeutig sein**
(unterschiedl. Wörter erhalten unterschiedl. Code)
Lösung: $encode$ als **Funktion** $encode : L_{in} \rightarrow \Sigma_{Bool}^*$
- **Kodierte Wörter müssen sich eindeutig dekodieren lassen**
Lösung: $encode$ muss **injektiv** sein
- **Möglichst einfache, endliche Beschreibung**
Lösung: beschreibe $encode$ als **homomorphe Fortsetzung**

Wiederholung: Mathematische Grundlagen 1

Relation: Seien A und B Mengen. Eine Relation R ist eine Teilmenge von $A \times B$. Relationen kann man auch grafisch veranschaulichen:




Anstelle von $(a, b) \in R$ schreibt man auch $a R b$, um auszudrücken, dass die Elemente a und b in Beziehung stehen. In unserem Beispiel gelten etwa $a R 2$ und $e R 2$.

Zu Relationen siehe auch [http://de.wikipedia.org/wiki/Relation_\(Mathematik\)](http://de.wikipedia.org/wiki/Relation_(Mathematik))

Wiederholung: Mathematische Grundlagen 2

Funktion: Seien A und B Mengen. Eine Relation R heißt Funktion, wenn Sie jedem Element der Menge A genau ein Element der Menge B zuordnet. Man spricht von einer Abbildung $R : A \rightarrow B$ mit **Definitionsbereich** A und **Bildbereich** B .




Anstelle von $(a, b) \in R$ schreibt man $R(a) = b$. In unserem Beispiel gelten etwa $R(a) = 2$ und $R(d) = 5$.

Wiederholung: Mathematische Grundlagen 3

Injektive Funktion: Eine Funktion $f : A \rightarrow B$ heißt injektiv (bzw. umkehrbar), falls


$$\forall x, y \in A : f(x) = f(y) \Leftrightarrow x = y$$



Wiederholung: Mathematische Grundlagen 4

Surjektive Funktion: Eine Funktion $f : A \rightarrow B$ heißt surjektiv, falls

$$\forall b \in B : \exists a \in A : f(a) = b$$



Eine Funktion heißt **bijektiv**, wenn Sie sowohl injektiv, als auch surjektiv ist.

Zu Funktionen siehe auch [http://de.wikipedia.org/wiki/Funktion_\(Mathematik\)](http://de.wikipedia.org/wiki/Funktion_(Mathematik))

Anmerkung: Funktionen in der Theoretischen Informatik

Eine Funktion ordnet **jedem** Element aus dem Wertebereich ein Element aus dem Bildbereich zu. Definitionslücken sind explizit zu berücksichtigen betrachte z.B.
 $kehrwert : \mathbb{R} - \{0\} \rightarrow \mathbb{R}$ mit

$$kehrwert(x) = \frac{1}{x}$$

In der Theoretischen Informatik ist man an konkreten Definitionslücken oft nicht interessiert und führt daher folgende Begriffe ein:

Definition 1.26

Sei $f : (A - D) \rightarrow B$ eine Funktion mit Definitionslücken $D \subseteq A$. f heißt

- **partielle Funktion** $f : A \rightarrow B$, wenn f u.U. nicht auf ganz A definiert ist
($kehrwert$ ist also eine partielle Funktion $kehrwert : \mathbb{R} \rightarrow \mathbb{R}$)
- **totale Funktion** $f : A \rightarrow B$, falls f auf ganz A definiert ist ($D = \emptyset$).

Beachte: nach dieser Definition ist jede totale Funktion auch partiell!

Homomorphismus 1

Definition 1.27 (Homomorphismus)

Seien Σ_1 und Σ_2 Alphabete. Eine Funktion $h : \Sigma_1^* \rightarrow \Sigma_2^*$ heißt Homomorphismus, gdw.

1. $h(\varepsilon) = \varepsilon$
2. $h(u \cdot v) = h(u) \cdot h(v)$ für $u, v \in \Sigma^*$

Beachte: Homomorphismen sind verträglich mit der Konkatenation - dem Konstruktör für Wörter.

Homomorphismus 2

Korollar 1.1

Sei $h : \Sigma_1^* \rightarrow \Sigma_2^*$ ein Homomorphismus. Dann gilt für jedes Wort $w = a_1 a_2 \dots a_n \in \Sigma_1^*$, $n \in \mathbb{N}$ mit $n \geq 1$ und $a_i \in \Sigma_1$ ($1 \leq i \leq n$):

$$h(w) = h(a_1)h(a_2)\dots h(a_n)$$

Beweis: vollständige Induktion über die Wortlänge von w .

Sei $w = a_1 a_2$ für $a_1, a_2 \in \Sigma \cup \{\varepsilon\}$. Da h ein Homomorphismus ist, folgt das Gewünschte sofort aus der Definition, denn $h(a_1 \cdot a_2) = h(a_1) \cdot h(a_2)$, $h(\varepsilon) = \varepsilon$ und ε ist rechts- und linksneutrales Element der Konkatenation. Sei nun $|w| = n$ mit $n > 2$, also $w = a_1 a_2 \dots a_{n-1} a_n$; dann gilt

$$\begin{aligned} h(w) &= h(a_1 a_2 \dots a_{n-1} a_n) \\ &= h(a_1 a_2 \dots a_{n-1})h(a_n) \\ &\quad h \text{ ist Homomorphismus} \\ &= h(a_1)h(a_2)\dots h(a_{n-1})h(a_n) \\ &\quad \text{Induktionsvoraussetzung} \end{aligned}$$



Ein Homomorphismus $h : \Sigma_1^* \rightarrow \Sigma_2^*$ ist durch seine Wirkung auf den Symbolen aus Σ_1 eindeutig bestimmt.

Definition 1.28 (Homomorphe Fortsetzung)

Sei $h : \Sigma_1 \rightarrow \Sigma_2^*$ eine Funktion. Die **homomorphe Fortsetzung** $h' : \Sigma_1^* \rightarrow \Sigma_2^*$ von h ist definiert durch

- $h'(\varepsilon) = \varepsilon$
- $h'(w \cdot a) = h'(w) \cdot h(a)$ für $w \in \Sigma_1^*, a \in \Sigma_1$

• Anmerkungen:

- Anstelle von h' werden wir oft einfach nur h schreiben.
- Ist $h : \Sigma_1 \rightarrow \Sigma_2^*$ injektiv, ist dies **nicht** hinreichend dafür, dass die homomorphe Fortsetzung $h' : \Sigma_1^* \rightarrow \Sigma_2^*$ injektiv ist!
- Kodierungsfunktionen *encode* definieren wir jetzt (bequem) als homomorphe Fortsetzung einer injektiven Funktion

Beispiel 1.22 (Kodierung von Graphen)

Adjazenzmatrizen hatten wir als Worte über dem Alphabet $\Sigma = \{0, 1, \#\}$ kodiert. Eine Kodierung über Σ_{Bool} $encode : \Sigma^* \rightarrow \Sigma_{Bool}^*$ erhalten wir z.B. durch homomorphe Fortsetzung von $h : \Sigma \rightarrow \Sigma_{Bool}^*$ mit

$$h(0) = 00$$

$$h(1) = 11$$

$$h(\#) = 10$$

Dann ist z.B.

$$\begin{aligned} encode(01\#\textcolor{red}{10}) &= h(0) \cdot h(1) \cdot h(\#) \cdot h(1) \cdot h(0) \\ &= 00 \cdot 11 \cdot 10 \cdot 11 \cdot 00 \end{aligned}$$

Definition 1.29 (Standardkodierung)

Sei $\Sigma = \{a_1, \dots, a_n\}$ ein Alphabet mit mindestens zwei Symbolen. Die **Standardkodierung** $encode : \Sigma^* \rightarrow \Sigma_{Bool}^*$ ist die homomorphe Fortsetzung von $h : \Sigma \rightarrow \Sigma_{Bool}^*$ mit

$$h(a_i) = Bin_{\lceil \log_2 n \rceil}(i-1)$$

wobei $Bin_j(m)$ der Binärdarstellung der Zahl m mit mindestens j Stellen entspricht (ggf. Auffüllen mit führenden Nullen).

Anmerkung: Sei $r \in \mathbb{R}$, dann beschreibt

- $\lceil r \rceil$ das kleinste $n \in \mathbb{N}$ mit $n \geq r$
- $\lfloor r \rfloor$ das größte $n \in \mathbb{N}$ mit $n \leq r$



- **Wir haben gelernt**

- wie man auch komplexere Daten durch Wörter (Sprachen) beschreiben kann
- dass Σ_{Bool} als Alphabet ausreichend ist (Homomorphismen)

- **Weitere Fragen bezüglich der Kodierung von Daten**

- Wie viele Wörter enthält eine Sprache, wenn Sie nicht unendlich ist?

[Wie viele Wörter hat z.B. $L_{Hamil}(G) = \{w \mid w \text{ kodiert Hamiltonschen Kreis in } G\}$]

- **Noch zu klären**

- Wie kodieren wir algorithmische Probleme mithilfe von Sprachen?
[Das sind Probleme, die wir durch Algorithmen lösen wollen]

- **Offen gebliebene Fragen zur Kodierung von Daten**

- Gibt es eine zu einem Datum eine kürzeste Darstellung als Wort über einem beliebigem Alphabet?

[Diese Frage hatten wir vertagt]