

Einführung in die Stochastik

Klausur am 01.02.13 Lösungen

Aufgabe 1:


Es sei K das Ereignis, dass Karl die richtige Antwort für eine Aufgabe kennt, und R das Ereignis, dass Karl die richtige Antwort ankreuzt. Gegeben sind die folgenden Wahrscheinlichkeiten

$$P(K) = 0,45, \quad P(R|K) = 1, \quad P(R|\bar{K}) = \frac{1}{6},$$

und somit auch

$$P(\bar{K}) = 0,55, \quad P(\bar{R}|K) = 0, \quad P(\bar{R}|\bar{K}) = \frac{5}{6}.$$

Wahrscheinlichkeitsbaum



- a) Die gesuchte Wahrscheinlichkeit für eine falsche Antwort, $P(\bar{R})$, ergibt sich mit Hilfe der Formel für die totale Wahrscheinlichkeit zu:

$$\begin{aligned} P(\bar{R}) &= P(\bar{R}|K) \cdot P(K) + P(\bar{R}|\bar{K}) \cdot P(\bar{K}) \\ &= 0 \cdot 0,45 + \frac{5}{6} \cdot 0,55 = 0,458\bar{3} \approx 45,83\% \end{aligned}$$

- b) Die gesuchte Wahrscheinlichkeit, mit der Karl eine richtige Antwort gewusst und nicht „erwürfelt“ hat, $P(K|R)$, ergibt sich zu:

$$\begin{aligned} P(K|R) &= \frac{P(K \cap R)}{P(R)} = \frac{P(R|K) \cdot P(K)}{1 - P(\bar{R})} = \frac{1 \cdot 0,45}{1 - 0,458\bar{3}} \\ &\approx 0,8308 = 83,08\% \end{aligned}$$

- c) Die Anzahl N der richtig beantworteten Aufgaben ist binomialverteilt mit der Versuchsanzahl $n = 8$ und der Trefferwahrscheinlichkeit

$$p = P(R) = 1 - P(\bar{R}) \approx 0,5417$$

Somit ergibt sich die gesuchte Wahrscheinlichkeit für genau vier richtige Antworten zu

$$\begin{aligned} P(N = 4) &= \binom{8}{4} \cdot p^4 \cdot (1 - p)^{8-4} \\ &= \frac{8 \cdot 7 \cdot 6 \cdot 5}{4 \cdot 3 \cdot 2 \cdot 1} \cdot 0,5417^4 \cdot 0,4583^4 \\ &= 70 \cdot 0,5417^4 \cdot 0,4583^4 = 26,59\% \end{aligned}$$

Aufgabe 2:

Die $\mathcal{N}(\vartheta, \sigma^2 = 25)$ -verteilte Zufallsgröße T beschreibe den Wert einer Messung der tatsächlichen Ofentemperatur ϑ mittels der Temperatursonde. Das Verfahren arbeitet einwandfrei genau dann, wenn $1064^\circ\text{C} < \vartheta < 1083^\circ\text{C}$. Wenn $\vartheta < 1064^\circ\text{C}$, schmilzt das Gold nicht, und wenn $\vartheta > 1083^\circ\text{C}$, schmilzt auch das Kupfer.

Es seien T_1, \dots, T_n die unabhängigen Stichprobenvariablen einer Stichprobe von T . Dann gilt

$$\frac{\bar{T}_n - \vartheta}{\sigma/\sqrt{n}} \sim N(0,1)$$

Als $(1 - \alpha)$ -Konfidenzintervall wählen wir

$$\begin{aligned} I(T_1, \dots, T_n) &= \left\{ \vartheta \left| -c \leq \frac{\bar{T}_n - \vartheta}{\sigma/\sqrt{n}} \leq c \right. \right\} \\ &= \left[\bar{T}_n - c \cdot \frac{\sigma}{\sqrt{n}}, \bar{T}_n + c \cdot \frac{\sigma}{\sqrt{n}} \right] \end{aligned}$$

c wird festgelegt durch die Konfidenzwahrscheinlichkeit $1 - \alpha = 0,95$:

$$\begin{aligned} P_\vartheta(\vartheta \in I(T_1, \dots, T_n)) &= P \left(-c \leq \frac{\bar{T}_n - \vartheta}{\sigma/\sqrt{n}} \leq c \right) \\ &\quad \sim N(0,1) \\ &= \Phi(c) - \Phi(-c) = \Phi(c) - (1 - \Phi(c)) \\ &= 2\Phi(c) - 1 = 1 - \alpha \quad (\text{mit } \alpha = 0,05) \\ \Rightarrow \quad \Phi(c) &= 1 - \frac{\alpha}{2} = 0,975 \\ \Rightarrow \quad c &= u_{1-\frac{\alpha}{2}} = u_{0,975} = 1,96 \end{aligned}$$

- a) Der aktuelle Wert einer Messung ergab $T = \bar{T}_1 = t = 1073^\circ\text{C}$. Hieraus ergibt sich als zweiseitiges 95%-Konfidenzintervall für ϑ mit $n = 1, \sigma = 5$:

$$\begin{aligned} I(t) &= [1073 - 1,96 \cdot 5 ; 1073 + 1,96 \cdot 5] \\ &= [1063,2 ; 1082,8] \end{aligned}$$

Mit einer statistischen Sicherheit von 95% liegt die tatsächliche Temperatur in diesem Intervall.

Da weder 1083°C noch eine höhere Temperatur im Konfidenzbereich liegt, kann mit einer statistischen Sicherheit von 95% davon ausgegangen werden, dass das Kupfer nicht schmilzt, und, da sowohl niedrigere als auch höhere Temperaturwerte als 1064°C im Konfidenzbereich liegen, kann über das Schmelzverhalten des Goldes und somit die einwandfreie Arbeitsweise des Verfahrens keine Aussage mit einer statistischen Sicherheit von 95% gemacht werden, das Gold kann, muss aber nicht schmelzen.

- b) Aus dem Konfidenzintervall kann mit einer statistischen Sicherheit von 95% auf die einwandfreie Arbeitsweise des Verfahrens geschlossen werden, wenn $I(t) \subseteq]1064, 1083[$. Somit muss, damit prinzipiell auf die einwandfreie Arbeitsweise des Verfahrens geschlossen werden kann, die Länge des Konfidenzintervalls kleiner als $1083 - 1064 = 19 [^\circ\text{C}]$ sein.

Die Länge des Intervalls basierend auf n Beobachtungen beträgt

$$l_n = 2c \frac{\sigma}{\sqrt{n}}$$

sie ist kleiner als $19[^\circ\text{C}]$ genau dann, wenn

$$l_n = 2c \frac{\sigma}{\sqrt{n}} = 2 \cdot 1,96 \cdot \frac{5}{\sqrt{n}} < 19$$

$$\Leftrightarrow \sqrt{n} > \frac{19,6}{19} \Leftrightarrow n > 1,06$$

Somit sind mindestens 2 Temperaturmessungen erforderlich.

Aufgabe 3:

Die $\mathcal{N}(\vartheta = 3, \sigma^2 = 9)$ -verteilte Zufallsgröße T beschreibe die sich nach der Reinigung einstellende Temperatur.

a) Die gesuchte Wahrscheinlichkeit $P(T > 9)$ ergibt sich wie folgt:

$$P(T > 9) = P\left(\frac{T - \vartheta}{\sigma} > \frac{9 - 3}{3}\right) = P\left(\frac{T - \vartheta}{\sigma} > 2\right) = 1 - \Phi(2)$$

$$= 1 - 0,97725 \quad \widehat{\sim N(0,1)}$$

$$= 0,02275 = 2,275\%$$

b) Die gesuchte Wahrscheinlichkeit $P(T < 9)$ ergibt sich wie folgt:

$$P(T < 0) = P\left(\frac{T - \vartheta}{\sigma} < \frac{0 - 3}{3}\right) = P\left(\frac{T - \vartheta}{\sigma} < -1\right) = \Phi(-1)$$

$$= 1 - \Phi(1) \quad \widehat{\sim N(0,1)}$$

$$= 1 - 0,84134 = 0,15866 = 15,866\%$$

c) Gesucht wird die Temperatur $t_{0,99}$ mit $P(T \leq t_{0,99}) = 0,99$. Diese ergibt sich wie folgt:

$$P(T \leq t_{0,99}) = P\left(\frac{T - \vartheta}{\sigma} \leq \frac{t_{0,99} - 3}{3}\right) = \Phi\left(\frac{t_{0,99} - 3}{3}\right) = 0,99$$

$$\quad \widehat{\sim N(0,1)}$$

$$\Leftrightarrow \frac{t_{0,99} - 3}{3} = u_{0,99} = 2,3263$$

$$\Leftrightarrow t_{0,99} = 3 \cdot u_{0,99} + 3 = 3 \cdot 2,3263 + 3 = 9,9789 [^\circ\text{C}]$$

Aufgabe 4:

a) Das Gerät muss höchstens einmal pro Jahr repariert werden genau dann, wenn $X_1 + X_2 \leq 1$. Die gesuchte Wahrscheinlichkeit ergibt sich somit wie folgt:

$$P(X_1 + X_2 \leq 1)$$

$$= P(X_1 = 0, X_2 = 0) + P(X_1 = 1, X_2 = 0) + P(X_1 = 0, X_2 = 1)$$

$$\stackrel{\substack{\text{unabh.} \\ X_1, X_2}}{=} P(X_1 = 0) \cdot P(X_2 = 0) + P(X_1 = 1) \cdot P(X_2 = 0)$$

$$+ P(X_1 = 0) \cdot P(X_2 = 1)$$

$$= 0,1 \cdot 0,1 + 0,1 \cdot 0,3 + 0,6 \cdot 0,1 = 0,1$$

b)

$$\begin{aligned}Y_1 &= 3X_1, & Y_2 &= 2X_2 + 1, & Z &= Y_1 + Y_2 \\E[X_1] &= 0 \cdot 0,1 + 1 \cdot 0,6 + 2 \cdot 0,3 = 1,2 \\E[X_2] &= 0 \cdot 0,1 + 1 \cdot 0,3 + 2 \cdot 0,5 + 3 \cdot 0,1 = 1,6 \\E[Z] &= E[3X_1 + 2X_2 + 1] \stackrel{E[\cdot] \text{ linear}}{=} 3E[X_1] + 2E[X_2] + 1 \\&= 3 \cdot 1,2 + 2 \cdot 1,6 + 1 = 7,8\end{aligned}$$

c)

$$\begin{aligned}\text{Var}(Y_1) &= \text{Var}(3X_1) = 9\text{Var}(X_1) = 9 \cdot (E[X_1^2] - E[X_1]^2) \\&= 9 \cdot ((0^2 \cdot 0,1 + 1^2 \cdot 0,6 + 2^2 \cdot 0,3) - 1,2^2) \\&= 9 \cdot (1,8 - 1,44) = 9 \cdot 0,36 = 3,24\end{aligned}$$

Aufgabe 5:

a) $f_{X,Y}$ ist eine Dichte genau dann, wenn $f_{X,Y} \geq 0$ und $\iint_{\mathbb{R}^2} f_{X,Y}(x,y) dx dy = 1$. Da

$$\begin{aligned}\iint_{\mathbb{R}^2} f_{X,Y}(x,y) dx dy &= \int_0^1 \int_0^1 cxy dx dy = c \int_0^1 x dx \int_0^1 y dy \\&= c \cdot \frac{x^2}{2} \Big|_0^1 \cdot \frac{y^2}{2} \Big|_0^1 = \frac{c}{4},\end{aligned}$$

liegt eine Dichte genau dann vor, wenn $c = 4$.

b) Für die marginale Dichte von X gilt:

$$f_X(x) = \int_{-\infty}^{\infty} f_{X,Y}(x,y) dy \stackrel{0 \leq x \leq 1}{=} \int_0^1 4xy dy = 4x \cdot \frac{y^2}{2} \Big|_0^1 = 2x$$

Somit lautet die marginale Dichte von X :

$$f_X(x) = \begin{cases} 2x & \text{für } 0 \leq x \leq 1 \\ 0 & \text{sonst} \end{cases}$$

c) Die marginale Verteilungsfunktion von X ergibt sich zu:

$$F_X = P(X \leq x) = \int_{-\infty}^x f_X(x) dx = \begin{cases} 0 & \text{für } x < 0 \\ x^2 & \text{für } 0 \leq x < 1 \\ 1 & \text{für } x \geq 1 \end{cases}$$

Aufgabe 6:

Die Zufallsgröße Y beschreibe den Bluttyp eines zufällig aus der Population ausgewählten Individuums. Es sei $Y = 1$, wenn MM der Bluttyp des Individuums ist, $Y = 2$ für NM und $Y = 3$ für NN. Die Wahrscheinlichkeitsfunktion von Y lautet dann:

$$\begin{aligned}p_1 &= P(Y = 1) = \theta^2, & p_2 &= P(Y = 2) = 2\theta(1 - \theta), \\p_3 &= P(Y = 3) = (1 - \theta)^2\end{aligned}$$

Y_1, \dots, Y_n seien die Stichprobenvariablen einer Stichprobe von Y vom Umfang n . Die gemeinsame Wahrscheinlichkeitsfunktion von Y_1, \dots, Y_n lautet:

$$\begin{aligned} P(Y_1 = y_1, \dots, Y_n = y_n) &= P(Y_1 = y_1) \cdot \dots \cdot P(Y_n = y_n) \\ &= p_{y_1} \cdot \dots \cdot p_{y_n} = p_1^{x_1} \cdot p_2^{x_2} \cdot p_3^{x_3} \\ &= (\theta^2)^{x_1} (2\theta(1-\theta))^{x_2} ((1-\theta)^2)^{x_3} \end{aligned}$$

wobei x_1, x_2, x_3 die absoluten Häufigkeiten der drei Bluttypen in der konkreten Stichprobe y_1, \dots, y_n sind. Die Likelihoodfunktion ergibt sich somit zu

$$\begin{aligned} L(\theta; y_1, \dots, y_n) &= \theta^{2x_1} \cdot 2^{x_2} \cdot \theta^{x_2} \cdot (1-\theta)^{x_2} (1-\theta)^{2x_3} \\ &= 2^{x_2} \cdot \theta^{2x_1+x_2} \cdot (1-\theta)^{x_2+2x_3} \rightarrow \max_{\theta} \end{aligned}$$

Für $\theta \neq 0; 1$ kann die Log-Likelihood-Funktion gebildet werden:

$$\begin{aligned} l(\theta; y_1, \dots, y_n) &= \log L(\theta; y_1, \dots, y_n) \\ &= x_1 \log 2 + (2x_1 + x_2) \log \theta + (x_2 + 2x_3) \log(1-\theta) \rightarrow \max_{\theta} \end{aligned}$$

$$\begin{aligned} \frac{d}{d\theta} l(\theta; y_1, \dots, y_n) &= \frac{2x_1 + x_2}{\theta} - \frac{x_2 + 2x_3}{1-\theta} \stackrel{!}{=} 0 \\ &\Leftrightarrow (2x_1 + x_2) \cdot (1-\theta) - (x_2 + 2x_3) \cdot \theta = 0 \\ &\Leftrightarrow \theta = \frac{2x_1 + x_2}{2x_1 + 2x_2 + 2x_3} = \frac{2x_1 + x_2}{2n} \\ \frac{d^2}{d\theta^2} l(\theta; y_1, \dots, y_n) &= -\frac{2x_1 + x_2}{\theta^2} - \frac{x_2 + 2x_3}{(1-\theta)^2} < 0 \quad \text{für } 0 < \theta < 1 \end{aligned}$$

Also ist

$$\hat{\theta} = \frac{2x_1 + x_2}{2n}$$

für $\hat{\theta} \neq 0; 1$ eine lokale Maximalstelle und die einzige lokale Extremumstelle der Log-Likelihoodfunktion und somit auch der Likelihoodfunktion in $]0; 1[$. Da die Likelihoodfunktion auf $[0; 1]$ stetig ist, folgt hieraus, dass

$$\hat{\theta} = \frac{2x_1 + x_2}{2n}$$

für $\hat{\theta} \neq 0; 1$ globale Maximalstelle der Likelihoodfunktion ist.

Für $\hat{\theta} = \frac{2x_1+x_2}{2n} = 0$, das heißt $x_1 = x_2 = 0$ und $x_3 = n$, ergibt sich

$$L(\theta; y_1, \dots, y_n) = (1-\theta)^{2n} < L(0; y_1, \dots, y_n) = 1 \quad \text{für } 0 < \theta \leq 1$$

und für $\hat{\theta} = \frac{2x_1+x_2}{2n} = 1$, das heißt $x_2 = x_3 = 0$ und $x_1 = n$,

$$L(\theta; y_1, \dots, y_n) = \theta^{2n} < L(1; y_1, \dots, y_n) = 1 \quad \text{für } 0 \leq \theta < 1$$

somit ist $\hat{\theta} = \frac{2x_1+x_2}{2n}$ auch für $\hat{\theta} = 0; 1$ globale Maximalstelle der Likelihoodfunktion.

Der Maximum-Likelihood-Schätzer für θ ist somit

$$\hat{\theta}_{ML} = \frac{2x_1 + x_2}{2n}.$$

Aufgabe 7:

Herr Huber erhält $n=6$ Karten, die rein zufällig aus 12 Karten ausgewählt werden, von denen $r = 4$ vom Typ „Parkett“ und $s = 8$ vom Typ „zweite Reihe“ sind. Die Zufallsgröße X beschreibe die Anzahl der Karten für das Parkett, die Herr Huber in Händen hält. X ist hypergeometrisch verteilt mit der Wahrscheinlichkeitsfunktion

$$P(X = k) = \frac{\binom{r}{k} \binom{s}{n-k}}{\binom{r+s}{n}} = \frac{\binom{4}{k} \binom{8}{6-k}}{\binom{12}{6}}$$

Die gesuchte Wahrscheinlichkeit ist $P(X \leq 1)$. Für sie ergibt sich.

$$\begin{aligned} P(X \leq 1) &= P(X = 0) + P(X = 1) \\ &= \frac{\binom{4}{0} \binom{8}{6}}{\binom{12}{6}} + \frac{\binom{4}{1} \binom{8}{5}}{\binom{12}{6}} = \frac{\frac{8 \cdot 7}{2} + 4 \cdot \frac{8 \cdot 7 \cdot 6}{3 \cdot 2}}{\frac{12 \cdot 11 \cdot 10 \cdot 9 \cdot 8 \cdot 7}{6 \cdot 5 \cdot 4 \cdot 3 \cdot 2}} \\ &= \frac{4 \cdot 7 + 4 \cdot 8 \cdot 7}{11 \cdot 3 \cdot 4 \cdot 7} = \frac{9}{33} \approx 0,2727 \end{aligned}$$

Aufgabe 8:

Die Dicke einer 1 € Münze wird beschrieben durch eine Zufallsgröße X mit Erwartungswert $E[X] = 1,5\text{mm}$ und Standardabweichung $\sigma_X = 0,2\text{mm}$. Die Höhe der 100.000 € Säule wird beschrieben durch die Zufallsgröße H mit

$$H = \sum_{i=1}^{100.000} X_i ,$$

wobei $X_1, \dots, X_{100.000}$ unabhängige und wie X verteilte Zufallsgrößen sind.

a) Da der Erwartungswertoperator additiv ist, ergibt sich für den Erwartungswert von H

$$\mu_H = E[H] = \sum_{i=1}^{100.000} E[X_i] = 100.000 \cdot 1,5\text{mm} = 150\text{m} ,$$

und da die Zufallsgrößen $X_1, \dots, X_{100.000}$ unabhängig sind, folgt für die Varianz

$$\begin{aligned} \sigma_H^2 &= \text{Var}(H) = \sum_{i=1}^{100.000} \text{Var}(X_i) = 100.000 \cdot (0,2\text{mm})^2 \\ &= 4000\text{mm}^2 = 4000 \cdot 10^{-6}\text{m}^2 = 0,004\text{m}^2 \end{aligned}$$

und für die Standardabweichung

$$\sigma_H = \sqrt{\text{Var}(H)} = \sqrt{0,004} \text{ m} \approx 0,06324555 \text{ m}$$

b) Die Tschebyscheffsche Ungleichung liefert für H die Abschätzung

$$P(|H - \mu_H| \geq c) \leq \frac{\sigma_H^2}{c^2}$$

Hieraus folgt

$$P(\mu_H - c < H < \mu_H + c) = 1 - P(|H - \mu_H| \geq c) \geq 1 - \frac{\sigma_H^2}{c^2}$$

Ein Intervall mit

$$P(\mu_H - c < H < \mu_H + c) \geq 0,9$$

ergibt sich, wenn c so gewählt wird, dass $1 - \frac{\sigma_H^2}{c^2} \geq 0,9$. Da

$$1 - \frac{\sigma_H^2}{c^2} \geq 0,9 \quad \Leftrightarrow \quad \frac{\sigma_H^2}{c^2} \leq 0,1 \quad \Leftrightarrow \quad c^2 \geq 10\sigma_H^2 = 0,04 \text{ m}^2$$

Mit $c = 0,2\text{m}$ ergibt sich ein möglichst kleines Intervall, dieses ist $[149,8; 150,2]$.

c) Gesucht wird der Wert h_{max} mit $P(H \leq h_{max}) = 0,9999$.

Aufgrund des zentralen Grenzwertsatzes gilt

$$\frac{H - \mu_H}{\sigma_H} \underset{as}{\sim} \mathfrak{N}(0,1)$$

Somit ergibt sich

$$\begin{aligned} 0,9999 &= P(H \leq h_{max}) \underset{\text{Norm.}}{\overset{\sim}{=}} P\left(\frac{H - \mu_H}{\sigma_H} \leq \frac{h_{max} - \mu_H}{\sigma_H}\right) \\ &\approx \Phi\left(\frac{h_{max} - \mu_H}{\sigma_H}\right) \end{aligned}$$

Hieraus folgt

$$\frac{h_{max} - \mu_H}{\sigma_H} = u_{0,9999} = 3,719$$

$$\begin{aligned} h_{max} &= \mu_H + u_{0,9999}\sigma_H = 150\text{m} + 3,719 \cdot \sqrt{0,004}\text{m} \\ &= 150,235\text{m} \end{aligned}$$