

# Stochastik

FH Aachen – Studienstandort Aachen  
5. Dezember 2025

Prof. Dr. Florian Heinrichs

# Klassierte Daten

# Einleitung

Manchmal<sup>1</sup> haben wir eine große Menge stetiger Daten und wollen diese zu Klassen zusammenfassen. Das Ergebnis sind *klassierte Daten*.

## Beispiel 136

Der Kundendienst eines Unternehmens misst die Wartezeiten, die Anrufer in einer Warteschleife verbringen mit folgendem Ergebnis:

$i$	Klasse	Dauer (min)	$h_i$ abs. Häufigkeit	$r_i$ rel. Häufigkeit	Klassenbreite
1	$A_1$	$0 \leq \cdot < 2$	1650	0.3300	2
2	$A_2$	$2 \leq \cdot < 4$	1111	0.2222	2
3	$A_3$	$4 \leq \cdot < 6$	720	0.1440	2
4	$A_4$	$6 \leq \cdot < 8$	508	0.1016	2
5	$A_5$	$8 \leq \cdot < 10$	332	0.0664	2
6	$A_6$	$10 \leq \cdot < 15$	427	0.0854	5
7	$A_7$	$15 \leq \cdot \leq 30$	252	0.0504	10
$\Sigma$			5000	1.0000	

<sup>1</sup>In der Klausur.


# Einleitung

## Beispiel 136

Der Kundendienst eines Unternehmens misst die Wartezeiten, die Anrufer in einer Warteschleife verbringen mit folgendem Ergebnis:


$i$	Dauer	$h_i$	$r_i$	KB
1	$[0, 2)$	1650	0.3300	2
2	$[2, 4)$	1111	0.2222	2
3	$[4, 6)$	720	0.1440	2
4	$[6, 8)$	508	0.1016	2
5	$[8, 10)$	332	0.0664	2
6	$[10, 15)$	427	0.0854	5
7	$[15, 30]$	252	0.0504	10

Achtung: Fläche der Rechtecke  
**proportional** zu  $h_i$ !



# Verteilungsfunktion

- > Wie können wir für klassierte Daten eine Verteilungsfunktion  $F_n$  zeichnen?
- > Für  $F_n$  sollte gelten:  $F_n(x) \approx \mathbb{P}(X \leq x)$
- > Wir wissen nur für die oberen Klassengrenzen, wie viele Beobachtungen kleiner oder gleich der Grenze sind.
- > Zeichne diese Punkte ein und interpoliere linear zwischen den Punkten.



# Mittelwert

---

- > Wie können wir für klassierte Daten den Mittelwert  $\bar{x}_n$  berechnen?
- > Sei  $\alpha_i$  die Klassenmitte der Klasse  $A_i$  mit absoluter Häufigkeit  $h_i$  und relativer Häufigkeit  $r_i$ .
- > Dann ist

$$\bar{x}_n \approx \tilde{x}_n := \frac{1}{n} \sum_{i=1}^k h_i \alpha_i = \sum_{i=1}^k r_i \alpha_i.$$

- > Im Beispiel:  $\tilde{x}_n \approx 5.23$

$i$	Dauer	$h_i$	$r_i$	$\alpha_i$
1	[0, 2)	1650	0.3300	1
2	[2, 4)	1111	0.2222	3
3	[4, 6)	720	0.1440	5
4	[6, 8)	508	0.1016	7
5	[8, 10)	332	0.0664	9
6	[10, 15)	427	0.0854	12.5
7	[15, 30]	252	0.0504	22.5

# Empirische Varianz

Wie können wir für klassierte Daten die empirische Varianz  $s^2$  berechnen?

- > Klassenmitte:  $\alpha_i$
- > Absolute Häufigkeit:  $h_i$
- > Relative Häufigkeit:  $r_i$
- > Mittelwert:  $\tilde{x}_n$
- > Dann ist

$$s^2 \approx \tilde{s}^2 := \frac{1}{n-1} \sum_{i=1}^k h_i (\alpha_i - \tilde{x}_n)^2.$$

$i$	Dauer	$h_i$	$r_i$	$\alpha_i$
1	[0, 2)	1650	0.3300	1
2	[2, 4)	1111	0.2222	3
3	[4, 6)	720	0.1440	5
4	[6, 8)	508	0.1016	7
5	[8, 10)	332	0.0664	9
6	[10, 15)	427	0.0854	12.5
7	[15, 30]	252	0.0504	22.5

- > Im Beispiel:  $\tilde{s}^2 \approx 27.83$

# Empirische Quantile

Wie können wir für klassierte Daten Quantile berechnen?

1. Berechne aus rel. Häufigkeit  $r_i$  die kumulierte rel. Häufigkeit  $F_i$ .
2. Finde "Einfallsklasse"  $A_i = [a_i, a_{i+1})$ , sodass  $F_i \geq p$  und  $F_{i-1} < p$ .
3. Innerhalb der Klasse: lineare Interpolation

$$q_p = a_i + \frac{p - F_{i-1}}{F_i - F_{i-1}}(a_{i+1} - a_i).$$

4. Was ist der Median im Beispiel?

$$i = 2: A_2 = [2, 4)$$

$$q_{0.5}$$

$$= 2 + \frac{0.5 - 0.33}{0.5522 - 0.33}(4 - 2)$$

$$\approx 3.53$$

Und  $q_{0.8}$ ?

$i$	Dauer	$h_i$	$r_i$	$F_i$
1	[0, 2)	1650	0.3300	0.3300
2	[2, 4)	1111	0.2222	0.5522
3	[4, 6)	720	0.1440	0.6962
4	[6, 8)	508	0.1016	0.7978
5	[8, 10)	332	0.0664	0.8642
6	[10, 15)	427	0.0854	0.9496
7	[15, 30]	252	0.0504	1.0000



# Modalklasse

---

1.  $A_i$  heißt *Modalklasse*, falls  $h_i = \max_{j=1}^k h_j$ .
2. Was ist der Modalklasse im Beispiel?  $A_1$
3. Informell: Die Modalklasse ist die häufigste Klasse.

$i$	Dauer	$h_i$	$r_i$	$F_i$
1	[0, 2)	1650	0.3300	0.3300
2	[2, 4)	1111	0.2222	0.5522
3	[4, 6)	720	0.1440	0.6962
4	[6, 8)	508	0.1016	0.7978
5	[8, 10)	332	0.0664	0.8642
6	[10, 15)	427	0.0854	0.9496
7	[15, 30]	252	0.0504	1.0000

# Übung

## Übung 86


Bei einer Zugverbindung von Jülich nach Aachen wurden in 100 Fahrten folgende Verspätungen (in Minuten) gemessen. Berechnen Sie aus der absoluten Häufigkeit  $h_i$  die relative Häufigkeit  $r_i$ , die kumulierte rel. Häufigkeit  $F_i$ , die Klassenbreite  $KB$  und die Klassenmitte  $\alpha_i$ .

Zeichnen Sie die empirische Verteilungsfunktion  $F_n$ . Bestimmen Sie  $\tilde{X}_n$ ,  $\tilde{s}^2$ ,  $q_{0.5}$ ,  $q_{0.9}$  und die Modalklasse.

$i$	Dauer	$h_i$	$r_i$	$F_i$	$\alpha_i$	KB
1	$[-2, 0)$	12				
2	$[0, 2)$	20				
3	$[2, 5)$	36				
4	$[5, 10)$	15				
5	$[10, 20)$	10				
6	$[20, 60)$	7				

# Literatur I

---


 Bundesministerium für Gesundheit (2024).

Infektionsradar.

https:

[//infektionsradar.gesund.bund.de/de/covid/inzidenz](https://infektionsradar.gesund.bund.de/de/covid/inzidenz).

Abgerufen: 2024-10-15.

 Dehling, H. and Haupt, B. (2006).

Einführung in die Wahrscheinlichkeitstheorie und Statistik.

Springer-Verlag.

# Literatur II

---



Dinnes, J., Sharma, P., Berhane, S., van Wyk, S., Nyaaba, N., Domen, J., Taylor, M., Cunningham, J., Davenport, C., Dittrich, S., Emperador, D., Hooft, L., Leeftang, M., McInnes, M., Spijker, R., Verbakel, J., Takwoingi, Y., Taylor-Phillips, S., Van den Bruel, A., and Deeks, J. (2022).

Rapid, point-of-care antigen tests for diagnosis of sars-cov-2 infection.

Cochrane Database of Systematic Reviews, (7).



Henze, N. et al. (1997).

Stochastik für Einsteiger, volume 4.  
Springer.